

# Proyecto de despliegue

Juan M. Alberola, Victor Sánchez, Lidia Contreras

Grado en Tecnologías Interactivas

## Recursos

- Carpeta **02-Proyecto\_despliegue** del repositorio de prácticas: <https://gitlab.com/Alberola/bigdatapRACTICAS>

## Introducción

En este proyecto vamos a analizar información sobre acciones del Ibex-35. Para ello, vamos a dividir el proceso en dos partes: extracción de la información y gestión de datos.

## Extracción de la información

En el repositorio de Git del apartado de recursos, tienes disponible un fichero `scraper.py`. Este repositorio es el mismo que utilizaste en la Tarea 1, con lo que puedes hacer un `git pull` sobre el mismo repositorio que ya tenías clonado.

Este fichero se encarga de procesar la información de la [web de Expansión](#) para recuperar información de cada acción. Para poder ejecutar este fichero, necesitas instalar el paquete ‘selenium’ desde dentro del entorno virtual. Este framework está pensado para automatizar pruebas en entornos web sin necesidad de intervención humana. Para nuestro caso, simplemente lo utilizaremos para acceder a los distintos elementos ‘html’ que nos interesan:

```
pip install selenium
```

A continuación, desde la página <https://pypi.org/project/selenium/>, en el apartado **Drivers**, haz clic en el de **Firefox** y descarga el **geckodriver** (**tar.gz** de 64 bits). Este driver es necesario para interactuar con nuestro navegador, que en nuestro caso, es Firefox. Una vez descargado, lo puedes descomprimir, borrar y mover a `/usr/local/bin`:

```
tar -xvzf geckodriver-v{VERSION}-linux64.tar.gz
rm geckodriver-v{VERSION}-linux64.tar.gz
mv geckodriver /usr/local/bin
```

Esto te creará un ejecutable que tendrás que alojar en el mismo directorio que el fichero `scraper.py`. Una vez hecho esto, podrás ejecutar este script de Python, donde se muestra por pantalla diversa información por cada acción:

ACCIONA,129.400,0.00,0.00,10.88,129.700,128.200,70789,7098,11:04  
ACERINOX,10.010,-0.25,-0.02,10.80,10.140,9.930,956930,2708,11:04  
ACS,27.250,0.74,0.20,2.03,27.370,26.780,630374,8466,11:04  
AENA,145.500,-0.07,-0.10,2.32,149.500,145.100,186816,21825,11:04

De todos estos valores, a nosotros únicamente nos interesan los siguientes valores:

- Nombre de la acción: primer valor.
- Última cotización: segundo valor.
- Máximo de la sesión: sexto valor.
- Mínimo de la sesión: séptimo valor.
- Fecha-Hora: último valor. El último valor del día, es posible que en vez de indicar la hora indique la fecha (p.e. 10/03)

Este fichero se deberá ejecutar cada vez que se quiera recuperar información. En concreto, queremos recuperar información cada hora, desde las 9:30 de la mañana hasta las 18:30 de la tarde de lunes a viernes. Para ello, puedes programar un **shell script** que se ejecute automáticamente según estos parámetros, almacenando la información que nos interesa. Puedes utilizar el comando **sleep** para pausar la ejecución durante el tiempo que quieras y el comando **date** para averiguar la hora y la fecha actual. No obstante, eres libre de obtener esta información de la manera que consideres. Para evitar que te capen la conexión, no hagas muchas llamadas seguidas. Para la finalidad de este proyecto, es suficiente con tener un script que funcione bien y recopilar algunos datos en varios días saltados.

Teniendo en cuenta esto, se deberá crear un fichero **diario** que contenga toda la información recuperada en un día concreto. Este fichero diario se almacenará en HDFS automáticamente al final de cada día, según la estructura de directorios que consideres.

## Gestión de los datos

Según la información almacenada, deberás programar diversos programas que te permitan obtener la siguiente información. Los programas deberán utilizar los ficheros almacenados en HDFS.

1. Generar un listado semanal (de la semana actual) donde se indique, para cada acción, su valor inicial, final, mínimo y máximo.
2. Generar un listado mensual (del mes actual) donde se indique, para cada acción, su valor inicial, final, mínimo y máximo.
3. Dado el nombre de una acción y un rango de fechas, obtener su valor mínimo y máximo de cotización, así como el porcentaje de decremento y de incremento desde el valor inicial de cotización hasta el mínimo y máximo, respectivamente.
4. Dado el nombre de una acción, recuperar su valor mínimo y máximo de cotización de la última hora, semana y mes.
5. Mostrar las 5 acciones que más han subido en la última semana y último mes.

6. Mostrar las 5 acciones que más han bajado en la última semana y último mes.
7. (Opcional) Dado un porcentaje y un rango de fechas, mostrar las acciones que han tenido un incremento de este porcentaje durante este período.

## Funcionalidad avanzada para llegar a la máxima nota

A parte de estas funcionalidades, deberás crear por lo menos un segundo fichero con información adicional de las distintas acciones, de manera que puedas hacer joins con los datos originales y estos nuevos. En este caso, se piden **tres funcionalidades extra** que hagan uso de joins. Se valorará la originalidad y que sean funcionalidades distintas a las realizadas.

## Presentación

Se realizará una presentación oral de unos 10 minutos, en donde se traten los siguientes puntos:

- Proceso de extracción de datos y organización de la información en HDFS y en local (si se almacena algo).
- Ejercicio 1 y 2. Esquema donde se vea qué entra y que sale de los procesos Map y Reduce, y un ejemplo de ejecución.
- Ejercicio 3 y 4. Esquema donde se vea qué entra y que sale de los procesos Map y Reduce, y un ejemplo de ejecución.
- Ejercicio 5 y 6. Esquema donde se vea qué entra y que sale de los procesos Map y Reduce, y un ejemplo de ejecución.
- Ejercicio 7 (si se ha realizado). Esquema donde se vea qué entra y que sale de los procesos Map y Reduce, y un ejemplo de ejecución.
- Funcionalidad avanzada (si se ha realizado).
- Conclusión general (qué os ha parecido el proyecto, mayores dificultades encontradas, así como cualquier comentario relevante).

## Entrega

Se entregarán los scripts necesarios y un documento *howto* que resuma cómo pueden ejecutarse. Pueden entregarse directamente en la plataforma o a través de un repositorio de Github. La presentación también se entregará.

Se realizará la entrega del proyecto en la plataforma dentro de la fecha límite. Además, se tendrá que mostrar el correcto funcionamiento en la sesión indicada por el profesor, el cual realizará preguntas y podrá proponer modificaciones para comprobar que se entiende.

## Criterios de evaluación

- Funcionamiento completo incluyendo parte avanzada: hasta 7 puntos.
- Funcionamiento completo sin incluir parte avanzada: hasta 5.5 puntos
- Funcionamiento hasta el ejercicio 6: hasta 5 puntos.
- Presentación: hasta 3 puntos.
- Cualquier modificación de estos criterios, se informará con suficiente antelación.